Detección de Pseudococcidae en cultivos de vid mediante visión por computadora

[1.er] Loo Jave, Paula Yucsian
Escuela de Ingeniería Informática
Universidad Nacional de Trujillo
Trujillo, Perú
ploo@unitru.edu.pe

[2.do] Malpartida Lara, Rodrigo
Escuela de Ingeniería Informática
Universidad Nacional de Trujillo
Trujillo, Perú
rmalpartidal@unitru.edu.pe

Resumen*— En *el presente artículo se desarrolla y evalúa un sistema de detección de Pseudococcidae en cultivos de vid mediante visión por computadora y aprendizaje profundo. Esta plaga afecta la calidad y productividad del cultivo, generando pérdidas económicas por deterioro de los racimos y restricciones fitosanitarias en los mercados de exportación. Se entrenó un modelo basado en la arquitectura YOLO11 sobre un conjunto de datos de acceso abierto, con preprocesamiento mediante CLAHE y filtrado bilateral. El modelo final alcanzó una precisión de 62.84%, sensibilidad de 42.13% y mAP@50 de 45.71%, con un tiempo de inferencia de 13.8 ms por imagen, superando al modelo público de referencia entrenado sobre el mismo conjunto de datos. Un estudio de ablación sobre cuatro hipótesis de mejora evidenció que la limitación principal reside en la cantidad y diversidad de los datos y no en la configuración del modelo. La evaluación sobre imágenes propias de campo del distrito de Gran Chimú reveló además una limitación de generalización por cambio de dominio. Los resultados sustentan la viabilidad computacional del enfoque para el monitoreo fitosanitario y establecen como requisito para su despliegue la incorporación de imágenes representativas del contexto local.

Palabras clave*— *aprendizaje profundo, cambio de dominio, cultivo de vid, detección de objetos, detección de plagas, Pseudococcidae, YOLO.

I. INTRODUCCIÓN

La vid constituye uno de los cultivos de mayor importancia económica para el sector agroexportador peruano, debido a la demanda de la uva de mesa en los mercados internacionales, su contribución a la generación de empleo y los ingresos que proporciona a los productores agrícolas. Durante la campaña 2025-2026, el Perú se consolidó como uno de los principales exportadores mundiales de uva de mesa, superando las 706 mil toneladas exportadas. Cabe precisar que, en términos de valor, durante la temporada 2022-2023 las exportaciones peruanas de uva de mesa alcanzaron los 1 498 millones de dólares, lo que representó un crecimiento del 16 % respecto de la campaña anterior. En consecuencia, este crecimiento exige mantener condiciones adecuadas de calidad, inocuidad y sanidad vegetal, debido a que la presencia de plagas puede limitar el acceso del producto a mercados con estrictos requisitos fitosanitarios.

Ahora bien, dentro de esta problemática se encuentra la presencia de insectos pertenecientes a la familia Pseudococcidae, conocidos comúnmente como cochinillas harinosas. Estos organismos se alimentan de la savia de la planta y pueden localizarse en hojas, tallos, brotes o racimos, ocasionando debilitamiento vegetal, deformaciones, pérdida de calidad del fruto y aparición de fumagina debido a la secreción de melaza. Al respecto, resulta determinante señalar que se trata de una plaga cuarentenaria para varios países importadores, de modo que la presencia de un solo insecto sobre los racimos, o incluso la fumagina desarrollada o la melaza que segrega, puede constituir causa de rechazo en las exportaciones. Por consiguiente, la afectación económica no se deriva únicamente de la pérdida de rendimiento, sino principalmente del riesgo de observaciones fitosanitarias, tratamientos adicionales o rechazo de cargamentos completos, lo que impacta directamente en la rentabilidad de los productores y en la competitividad del sector vitivinícola.

Esta situación adquiere especial importancia en la región La Libertad —cuarta región del país en superficie cultivada de uva de mesa, después de Ica, Piura y Lambayeque—, particularmente en la provincia de Gran Chimú, donde la producción de vid constituye una de las principales actividades económicas de numerosas familias. La provincia cuenta con aproximadamente 1 200 hectáreas destinadas a este cultivo, una producción anual cercana a las 30 mil toneladas y un valor bruto que supera los 81 millones de soles. Sin embargo, el monitoreo de plagas se realiza principalmente mediante inspecciones visuales, procedimiento que demanda tiempo, depende de la experiencia del evaluador y puede presentar variaciones en la identificación de los insectos.

Asimismo, la inspección convencional presenta dificultades para detectar infestaciones durante sus etapas iniciales. Esta limitación se agrava por el comportamiento biológico de la plaga, dado que las cochinillas pasan el invierno ubicadas en el tronco y los brazos principales, bajo la ritidoma o corteza de la vid, y la primera generación se localiza igualmente bajo la corteza. En efecto, un estudio de monitoreo poblacional realizado en el distrito de Majes, Arequipa, sobre las variedades Thompson Seedless y Red Globe, registró que el punto de evaluación con mayor población de Planococcus ficus fue el tercio medio del tallo,

con promedios de 15.16 hembras adultas, y que la etapa fenológica de maduración concentró la mayor densidad poblacional, alcanzando 33.93 hembras adultas. Por lo tanto, los focos de infestación se concentran preferentemente en la estructura leñosa de la planta, donde permanecen ocultos a la observación directa, lo que puede retrasar la aplicación de medidas de control, favorecer la propagación de la plaga e incrementar el uso de productos químicos. En atención a ello, se requiere una herramienta tecnológica que complemente la evaluación realizada por el personal agrícola, facilite la identificación oportuna de Pseudococcidae y proporcione resultados más rápidos durante las actividades de monitoreo.

Ante esta necesidad, la visión por computadora representa una alternativa para analizar imágenes digitales e identificar automáticamente objetos de interés. Dentro de este campo, los modelos de aprendizaje profundo basados en redes neuronales convolucionales permiten extraer características relacionadas con la forma, el color, la textura y la ubicación de los organismos presentes en una imagen. Adicionalmente, los modelos de la familia YOLO —You Only Look Once— realizan la detección y localización de objetos en una sola etapa, lo que favorece una mayor velocidad de procesamiento frente a otros métodos que requieren varias fases de análisis.

Con relación a los antecedentes internacionales, en primer lugar, Wu et al. (2019) desarrollaron el conjunto de datos IP102. El objetivo de dicho estudio consistió en proporcionar un recurso estandarizado para el reconocimiento automático de plagas agrícolas. En cuanto al método, los autores construyeron un corpus de 75 222 imágenes distribuidas en 102 categorías de insectos, sobre el cual entrenaron y compararon las arquitecturas ResNet-50, VGG-16, GoogLeNet e InceptionV3. Respecto de los resultados, ResNet-50 alcanzó una exactitud Top-1 de 49.4 % y una exactitud Top-5 de 76.2 %. En conclusión, el estudio evidencia la utilidad de los conjuntos de datos especializados para entrenar modelos de aprendizaje profundo; no obstante, demuestra que la clasificación de plagas continúa siendo una tarea compleja debido a las semejanzas visuales existentes entre especies distintas.

Por su parte, Chen et al. (2021) desarrollaron una aplicación móvil para la detección de insectos escama, incluida la cochinilla harinosa. El objetivo del trabajo fue evaluar comparativamente distintos métodos de detección de objetos aplicados a la identificación automática de estas plagas. En lo referente al método, los autores emplearon un conjunto de imágenes anotadas de insectos escama y compararon el desempeño de arquitecturas de detección de una y dos etapas, entre ellas YOLOv4, integrando el modelo resultante en una aplicación para teléfonos inteligentes. En cuanto a los resultados, el sistema alcanzó una exactitud del 100 % en la detección de la clase correspondiente a cochinilla harinosa. Se concluye que los detectores de una etapa resultan viables para el despliegue en dispositivos móviles orientados al monitoreo fitosanitario; sin embargo, debe considerarse que dichos resultados se obtuvieron sobre imágenes de primer plano en condiciones controladas, lo que difiere de los escenarios de campo abierto.

De manera complementaria, Zheng et al. (2019) desarrollaron el conjunto de datos CropDeep. El objetivo de la investigación fue disponer de una base de imágenes agrícolas obtenidas en condiciones reales de producción. En relación con el método, se recolectaron y anotaron más de 31 000 imágenes, sobre las cuales se evaluaron los modelos Faster R-CNN, SSD y YOLOv3 en tareas de reconocimiento y localización de cultivos bajo variaciones de iluminación, orientación y fondo. En cuanto a los resultados, YOLOv3 alcanzó un mAP de 81.0 % con un tiempo de inferencia de 22 milisegundos por imagen. Por consiguiente, el estudio concluye que los modelos YOLO presentan una relación favorable entre precisión y velocidad, condición necesaria para su implementación en sistemas de monitoreo agrícola en tiempo real.

En el ámbito nacional, Basilio Vela (2016) desarrolló un sistema de visión computacional aplicado al control de calidad de uva de mesa. El objetivo consistió en determinar automáticamente el tamaño y el peso de los racimos sin establecer contacto directo con el producto. Con respecto al método, el autor implementó un procedimiento de captura de imágenes, extracción de características visuales y clasificación mediante redes neuronales artificiales, tomando como referencia la norma técnica peruana NTP 011.012-2005 para la categorización de los racimos según su calibre. En lo relativo a los resultados, el sistema obtuvo una eficiencia del 95 % en la clasificación por tamaño y del 70 % en la clasificación por peso. En consecuencia, se concluye que la visión por computadora puede aplicarse en la agroindustria vitivinícola peruana para disminuir la intervención manual y estandarizar los procesos de evaluación, aunque el desempeño varía sustancialmente según el atributo estimado.

En el contexto regional, Narciso y Manzano (2021) desarrollaron un sistema de visión artificial para la selección de arándanos según estándares de exportación en empresas agroindustriales de La Libertad. El objetivo fue detectar automáticamente los cinco defectos más frecuentes del fruto —corola, desgarrado, picado de pájaro, pedicelo y rojo— identificados previamente mediante consulta a expertos. En cuanto al método, los autores construyeron una base de datos propia de 820 imágenes, de las cuales emplearon 500 etiquetadas manualmente, y entrenaron el modelo de detección Faster R-CNN durante 41 400 pasos sobre la plataforma TensorFlow, evaluando el desempeño mediante el criterio de Intersección sobre Unión. Respecto de los resultados, la precisión osciló entre 24 % y 40.5 % según el defecto considerado, con un tiempo de procesamiento aproximado de cinco segundos por imagen. Los autores concluyen que la principal causa del desempeño obtenido reside en la cantidad de imágenes utilizadas durante el entrenamiento, y que los resultados podrían mejorarse enriqueciendo la base de datos. Este trabajo constituye un precedente directo para la presente investigación, no solo por su ámbito regional, sino porque identifica la disponibilidad de datos —y no la arquitectura— como el factor limitante en tareas de detección aplicadas a la agroindustria liberteña..

En síntesis, a partir de los antecedentes revisados se observa que los modelos de visión por computadora han sido

utilizados principalmente para clasificar plagas, reconocer enfermedades o evaluar la calidad de los racimos. No obstante, persiste una limitada aplicación de estos modelos para detectar específicamente Pseudococcidae en cultivos de vid de la provincia de Gran Chimú. Además, los estudios previos han trabajado mayoritariamente con imágenes de hoja y fruto en condiciones controladas, mientras que la infestación inicial se localiza bajo la corteza del tronco. Esta brecha justifica el desarrollo de un sistema que no solo determine si la plaga aparece en una imagen, sino que también permita localizarla mediante cuadros delimitadores, facilitando la revisión de las zonas afectadas.

En cuanto a la justificación del estudio, la importancia científica del proyecto radica en generar evidencia sobre la aplicación de modelos de aprendizaje profundo en la detección automática de plagas agrícolas. En el ámbito tecnológico, permite implementar un sistema basado en YOLO para procesar imágenes, identificar ejemplares de Pseudococcidae y señalar su ubicación. Desde una perspectiva práctica, la herramienta puede complementar las inspecciones visuales, disminuir el tiempo destinado a la revisión de las plantas y facilitar la detección de posibles focos de infestación. Finalmente, en el ámbito económico y social, su aplicación podría contribuir a disminuir pérdidas, fortalecer el manejo fitosanitario y favorecer la adopción de tecnologías de agricultura de precisión entre los productores de vid.

Respecto de la funcionalidad del sistema, esta comprende la recepción de imágenes digitales de hojas, tallos o racimos, seguida de su procesamiento mediante un modelo YOLO previamente entrenado. Como resultado, el sistema muestra la imagen analizada con cuadros delimitadores alrededor de los ejemplares detectados, acompañados por la clase correspondiente y su nivel de confianza. Para el entrenamiento se utilizaron conjuntos de datos públicos con imágenes anotadas de Pseudococcidae, mientras que las fotografías obtenidas en cultivos de vid de Gran Chimú se emplearon para evaluar el comportamiento del modelo en condiciones de campo.

En función de la problemática descrita, se plantea la siguiente pregunta de investigación: ¿en qué medida un sistema basado en visión por computadora y el algoritmo YOLO permite detectar automáticamente Pseudococcidae en imágenes de cultivos de vid de la provincia de Gran Chimú?

En correspondencia con esta interrogante, el objetivo general del proyecto es desarrollar un sistema de visión por computadora basado en el algoritmo YOLO para detectar automáticamente Pseudococcidae en imágenes de cultivos de vid de la provincia de Gran Chimú. De manera específica, se busca: recopilar y depurar imágenes provenientes de conjuntos de datos públicos; unificar las clases y anotaciones relacionadas con Pseudococcidae; preparar las imágenes mediante técnicas de redimensionamiento, normalización y aumento de datos; entrenar modelos de detección pertenecientes a la familia YOLO; comparar su desempeño mediante métricas de precisión, exhaustividad, F1-score y mAP; y, finalmente, evaluar cualitativamente la capacidad del modelo seleccionado mediante imágenes obtenidas en condiciones reales de campo.

II. Materiales y métodos

A. Enfoque metodológico

La presente investigación corresponde a un enfoque cuantitativo, ya que el desempeño del sistema propuesto se evalúa mediante métricas numéricas obtenidas durante el entrenamiento y la validación del modelo de detección de objetos. Asimismo, se clasifica como una investigación aplicada, debido a que busca desarrollar una solución tecnológica para apoyar el monitoreo fitosanitario de cultivos de vid mediante técnicas de visión por computadora e inteligencia artificial.

El diseño metodológico es de tipo experimental computacional, puesto que se implementaron y compararon diferentes configuraciones del modelo YOLO11 bajo condiciones controladas, modificando variables como la arquitectura empleada y la preparación del conjunto de datos, con el propósito de determinar la configuración que ofreciera el mejor desempeño en la detección de *Pseudococcidae*.

El desarrollo del proyecto comprendió la obtención y preparación del conjunto de datos, la aplicación de técnicas de aumento de datos (*Data Augmentation*), el entrenamiento de modelos YOLO11 y la evaluación de su desempeño mediante métricas cuantitativas. Además, se realizó una validación cualitativa utilizando fotografías reales de cultivos de vid en la provincia de Gran Chimú, las cuales no fueron empleadas durante el entrenamiento, sino únicamente para evaluar el comportamiento del modelo frente a imágenes externas.

B. Equipos especializados y recursos tecnológicos

El desarrollo del sistema se realizó utilizando un equipo portátil con capacidad para el entrenamiento de modelos de aprendizaje profundo. Las especificaciones del equipo utilizado se presentan en la Tabla 1.

Tabla 1
Especificaciones de los equipos utilizados

Componente	Especificación	Equipo de adquisión
Modelo	Lenovo Legion 5	Samsung Galaxy A15
Procesador	AMD Ryzen 5	MediaTek Helio G99
Memoria RAM	8 GB DDR5	8 GB RAM
Almacenamiento	SSD NVMe 512 GB	256 GB
Tarjeta gráfica	NVIDIA GeForce RTX 3050 Laptop GPU (4 GB VRAM)	—
Cámara	—	Principal de 50 MP (f/1.8, enfoque automático), ultra gran angular de 5 MP y macro de 2 MP
Sistema operativo	Windows 11	Android 14

El entrenamiento del modelo se realizó utilizando el equipo Lenovo Legion 5, aprovechando la aceleración por GPU proporcionada por la tarjeta gráfica NVIDIA GeForce RTX 3050 para el procesamiento de redes neuronales profundas.

Para la captura de las fotografías de campo se empleó un Samsung Galaxy A15, utilizando exclusivamente la cámara principal de 50 MP, debido a su mayor resolución y capacidad para registrar detalles de las hojas, racimos y zonas afectadas por la presencia de *Pseudococcidae*.

Previamente a la adquisición de las imágenes se efectuó una calibración operativa del dispositivo, con el propósito de estandarizar las condiciones de captura. Para ello se mantuvieron parámetros constantes, como el uso de la cámara principal, la resolución máxima disponible, el enfoque automático, la iluminación natural y una distancia aproximada uniforme entre la cámara y el cultivo. Esta estandarización permitió obtener imágenes homogéneas, reduciendo la variabilidad durante la evaluación del modelo en condiciones reales.

Como entorno de desarrollo se empleó Anaconda junto con Jupyter Notebook, utilizando Python como lenguaje de programación.

Las principales bibliotecas utilizadas fueron:

- Ultralytics YOLO11
- PyTorch
- OpenCV
- Albumentations
- NumPy
- Pandas
- Matplotlib
- Scikit-image

Estas herramientas permitieron realizar el procesamiento de imágenes, la preparación del conjunto de datos, el entrenamiento del modelo y la evaluación de los resultados obtenidos.

C. Datasets

El conjunto de datos utilizado en esta investigación proviene del dataset público Mealybug v8, disponible en la plataforma Roboflow Universe, el cual contiene imágenes previamente anotadas mediante cuadros delimitadores (*bounding boxes*) para la detección de cochinillas harinosas (*Pseudococcidae*).

Inicialmente el dataset contenía tres clases (Grape, Leaf y Pseudococcidae). Sin embargo, debido al fuerte desbalance existente entre ellas, se decidió desarrollar el modelo considerando únicamente la clase Pseudococcidae, ya que constituye el objetivo principal de la investigación.

Para incrementar la cantidad y variabilidad de imágenes de entrenamiento se aplicó una estrategia de Data Augmentation mediante la biblioteca Albumentations, utilizando transformaciones de:

- Volteo horizontal.
- Rotación aleatoria.
- Variación de brillo y contraste.
- Ajuste de tono, saturación y valor (HSV).
- Ecualización adaptativa del histograma (CLAHE).

Estas transformaciones se aplicaron únicamente al conjunto de entrenamiento, evitando modificar las imágenes destinadas a validación.

Como resultado del proceso de aumento de datos, el conjunto quedó conformado por:

- Entrenamiento: 2331 imágenes.
- Validación: 68 imágenes.

Adicionalmente, se recopilaron fotografías reales de cultivos de vid en la provincia de Gran Chimú (La Libertad, Perú). Estas imágenes no fueron utilizadas durante el entrenamiento, sino exclusivamente para realizar una evaluación cualitativa del comportamiento del modelo en condiciones reales de campo.

D. Métricas de evaluación

El desempeño del modelo fue evaluado mediante indicadores ampliamente utilizados en tareas de detección de objetos.

Las métricas consideradas fueron:

- Precisión (Precision): mide la proporción de detecciones correctas respecto al total de detecciones realizadas por el modelo.
- Exhaustividad (Recall): indica la capacidad del modelo para detectar correctamente los objetos presentes en las imágenes.
- F1-Score: representa el equilibrio entre precisión y exhaustividad mediante su media armónica.
- mAP@0.5: evalúa la precisión media considerando un umbral de Intersección sobre Unión (IoU) de 0.5.
- mAP@0.5:0.95: proporciona una evaluación más estricta del desempeño al considerar múltiples umbrales de IoU.
- Tiempo de inferencia por imagen: mide el tiempo requerido por el modelo para procesar una imagen y generar las detecciones correspondientes.

Estas métricas permitieron comparar objetivamente las diferentes configuraciones evaluadas y seleccionar el modelo con mejor desempeño.

E. Técnicas de análisis

El análisis comprende el preprocesamiento de las imágenes mediante redimensionamiento, normalización y técnicas de aumento de datos (Data Augmentation), como rotación, volteo horizontal, escalado y variación del brillo. Posteriormente, se entrena el modelo YOLO utilizando el conjunto de entrenamiento y se analiza su comportamiento mediante las curvas de Loss, Precision, Recall y mAP, con el

fin de evaluar la convergencia del modelo y detectar posibles problemas de sobreajuste o subajuste. La Figura 1 presenta el flujo general de la metodología propuesta.

Figura 1

Diagrama del proceso de la metodología propuesta



F. Técnicas de validación

La validación del sistema se realizó utilizando el conjunto de validación del dataset, sobre el cual se evaluó el desempeño del modelo mediante las métricas Precision, Recall, F1-Score, mAP@0.5, mAP@0.5:0.95 y el tiempo de inferencia por imagen. Asimismo, se empleó la matriz de confusión para analizar la capacidad del modelo de identificar correctamente la presencia de *Pseudococcidae*, considerando los verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos.

Como complemento, se efectuó una validación cualitativa utilizando fotografías reales obtenidas en cultivos de vid de la provincia de Gran Chimú. Estas imágenes, al no contar con anotaciones (*Ground Truth*), se emplearon únicamente para observar el comportamiento del modelo en condiciones reales de campo y verificar visualmente la detección de la plaga. Finalmente, se analizaron las curvas de entrenamiento (*Loss*, *Precision*, *Recall* y *mAP*) y se presentaron ejemplos representativos de las detecciones obtenidas.

III. DESARROLLO DEL PROYECTO

A. Análisis inicial

La familia Pseudococcidae, conocida comúnmente como cochinillas harinosas, constituye una de las principales plagas que afectan los cultivos de vid, debido a que sus individuos se alimentan de la savia de la planta, debilitando su desarrollo y favoreciendo la aparición de enfermedades secundarias que reducen la calidad y el rendimiento de la producción.

Actualmente, la identificación de ejemplares pertenecientes a la familia Pseudococcidae se realiza principalmente mediante inspecciones visuales efectuadas por personal especializado, un procedimiento que demanda tiempo, experiencia y cuyos resultados pueden verse influenciados por la subjetividad del observador y las condiciones ambientales.

Frente a esta problemática, se planteó el desarrollo de un sistema basado en técnicas de visión por computadora y aprendizaje profundo, capaz de detectar automáticamente individuos pertenecientes a la familia Pseudococcidae en imágenes de cultivos de vid mediante el algoritmo YOLO11. El objetivo es proporcionar una herramienta de apoyo para el monitoreo fitosanitario, permitiendo identificar oportunamente focos de infestación y facilitar la toma de decisiones durante las labores de inspección agrícola.

Como primera etapa del proyecto, se realizó un análisis de los requerimientos funcionales y técnicos necesarios para el desarrollo del sistema. Asimismo, se evaluó la disponibilidad de conjuntos de datos públicos especializados en la detección de Pseudococcidae, así como la posibilidad de complementar la evaluación mediante fotografías reales obtenidas en cultivos de vid de la provincia de Gran Chimú.

A partir de este análisis, se establecieron los siguientes requerimientos principales del sistema:

- Detectar automáticamente individuos pertenecientes a la familia Pseudococcidae en imágenes de cultivos de vid.
- Localizar la plaga mediante cuadros delimitadores (*bounding boxes*).
- Mostrar el nivel de confianza asociado a cada detección.
- Procesar imágenes individuales en un tiempo reducido para apoyar las actividades de monitoreo fitosanitario.

Figura 2

Comparativa entre el método tradicional y el sistema propuesto basado en YOLO



El alcance del proyecto comprende la detección automática de individuos pertenecientes a la familia Pseudococcidae en imágenes digitales de cultivos de vid mediante un modelo de detección de objetos basado en YOLO11. El sistema procesa cada imagen de entrada, identifica las regiones donde se encuentra la plaga y presenta como resultado la ubicación de cada detección junto con su nivel de confianza.

No obstante, la propuesta presenta algunas limitaciones. El sistema fue desarrollado para analizar imágenes estáticas y su desempeño depende directamente de

la calidad, cantidad y diversidad del conjunto de datos empleado durante el entrenamiento. Asimismo, el modelo está orientado exclusivamente a la detección de Pseudococcidae, por lo que no identifica otras plagas o enfermedades presentes en el cultivo ni ejecuta acciones de control fitosanitario.

B. Diseño de alto nivel

El sistema propuesto fue diseñado siguiendo una arquitectura modular compuesta por cinco etapas principales: adquisición de imágenes, preparación y preprocesamiento del conjunto de datos, entrenamiento del modelo de detección, inferencia y visualización de resultados. Esta organización permite estructurar el flujo de procesamiento de manera independiente, facilitando el mantenimiento del sistema, la incorporación de nuevos conjuntos de datos y la actualización del modelo sin modificar la arquitectura general. La Figura 3 muestra la arquitectura general del sistema.

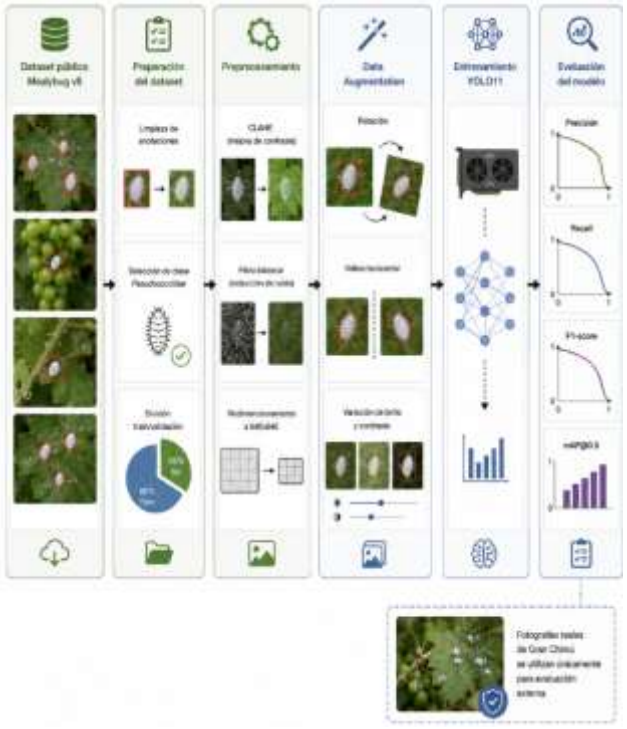
Figura 3
Arquitectura general del sistema



Cada módulo interactúa de manera secuencial, permitiendo transformar una imagen de entrada en un resultado final que identifica la presencia de Pseudococcidae mediante cuadros delimitadores (*bounding boxes*) y proporciona el nivel de confianza asociado a cada detección. De esta manera, el sistema integra las etapas de procesamiento de imágenes y aprendizaje profundo para automatizar la identificación de la plaga en cultivos de vid.

De forma general, el funcionamiento del sistema comprende dos escenarios principales: entrenamiento y ejecución. Durante la fase de entrenamiento, se emplea el conjunto de datos público Mealybug v8, compuesto por imágenes anotadas de Pseudococcidae, las cuales pasan por un proceso de preparación que incluye redimensionamiento, normalización, preprocesamiento mediante CLAHE y filtrado bilateral, además de técnicas de aumento de datos aplicadas únicamente al conjunto de entrenamiento. Posteriormente, las imágenes son organizadas en conjuntos de entrenamiento y validación para realizar el ajuste del modelo YOLO11 y evaluar su desempeño mediante métricas como Precision, Recall, F1-score y mAP. La Figura 4 representa el flujo correspondiente a esta etapa.

Figura 4
Escenario de entrenamiento del sistema



Durante la etapa de entrenamiento, el modelo aprende las características visuales asociadas a Pseudococcidae a partir de las imágenes anotadas, generando los parámetros necesarios para realizar detecciones sobre nuevas imágenes. Las fotografías obtenidas en cultivos de vid de Gran Chimú no forman parte del entrenamiento, sino que son utilizadas posteriormente para evaluar cualitativamente la capacidad de generalización del modelo en condiciones reales de campo.

En la fase de ejecución, el sistema recibe una imagen digital de un cultivo de vid como entrada y utiliza el modelo YOLO11 previamente entrenado para analizarla e identificar posibles ejemplares de Pseudococcidae. Como resultado, se genera una imagen de salida con cuadros delimitadores alrededor de las regiones detectadas, indicando la clase correspondiente y el porcentaje de confianza asociado a cada predicción. La Figura 5 presenta el escenario de ejecución del sistema.

Figura 5
Escenario de ejecución del sistema



Este flujo permite automatizar el proceso de detección de la plaga y proporcionar información visual que facilite la inspección fitosanitaria, reduciendo la dependencia exclusiva de la evaluación manual y permitiendo una respuesta más rápida durante las actividades de monitoreo del cultivo.

.

C. Diseño detallado

El sistema fue desarrollado en Python utilizando Anaconda y Jupyter Notebook como entorno de desarrollo. La detección de Pseudococcidae fue implementada mediante la biblioteca Ultralytics YOLO11, mientras que OpenCV fue empleado para el procesamiento y visualización de imágenes. Asimismo, se utilizaron herramientas como Albumentations para aumento de datos y PyTorch para el entrenamiento acelerado mediante GPU.

El diseño del sistema comprende cinco etapas principales: adquisición y preparación de datos, preprocesamiento, entrenamiento del modelo, detección y evaluación de resultados.

Etapa 1: Adquisición de imágenes

Las imágenes fueron obtenidas del dataset público Mealybug v8 de Roboflow Universe, inicialmente compuesto por las clases Grape, Leaf y Pseudococcidae. Debido al desbalance entre categorías, el modelo final fue entrenado únicamente para detectar la clase Pseudococcidae. Además, se realizó una depuración de anotaciones eliminando cuadros delimitadores con áreas extremadamente pequeñas.

Etapa 2: Preprocesamiento

Las imágenes fueron redimensionadas a 640 × 640 píxeles y normalizadas al rango [0,1]. Se aplicó mejora de contraste mediante CLAHE y reducción de ruido mediante filtrado bilateral. Posteriormente, se emplearon técnicas de aumento de datos como rotación, volteo horizontal y variación de brillo y contraste para incrementar la diversidad del conjunto de entrenamiento.

Etapa 3: Entrenamiento con YOLO

Se utilizó el modelo YOLO11n mediante aprendizaje por transferencia con pesos preentrenados. Los parámetros principales del entrenamiento se presentan en la Tabla 2.

Tabla 2

Parámetros de entrenamiento del modelo

Parámetro	Valor
Modelo base	YOLO11n
Clases	1 (Pseudococcidae)
Épocas	100
Tamaño de imagen	640 × 640 px
Batch size	8
Patience	20
Dispositivo	NVIDIA RTX 3050 GPU

Etapa 4: Detección y visualización

El desempeño del sistema fue evaluado mediante Precision, Recall, F1-score, mAP@0.5 y mAP@0.5:0.95. Además, se analizaron las curvas de entrenamiento y la matriz de confusión para identificar el comportamiento del modelo durante la validación.

IV. ANÁLISIS DE RESULTADOS

A. Comparación de configuraciones del modelo

Con el objetivo de analizar el efecto de la arquitectura del modelo y la depuración de anotaciones sobre la detección de Pseudococcidae, se realizaron diferentes experimentos manteniendo el mismo conjunto de validación. La Figura 6 presenta la comparación entre las configuraciones evaluadas.

Figura 6

Comparación de configuraciones evaluadas bajo el mismo conjunto de validación

Configuración	Dataset entren.	Precision	Recall	mAP@0.5	mAP@0.5:0.95	F1
v3 — YOLO11n	dataset_final_v2	62.84%	42.13%	45.71%	22.77%	50.44%
v4 — YOLO11s	dataset_final_v2	54.55%	40.28%	41.51%	20.54%	46.34%
v5 — YOLO11n	dataset_final_v3	61.45%	39.85%	45.05%	21.87%	48.35%

Los resultados evidencian que la configuración V3 basada en YOLO11n obtuvo el mejor desempeño general, alcanzando un mAP@0.5 de 45.71%, una precisión de 62.84% y un F1-score de 50.44%.

La comparación entre V3 y V4 demuestra que el incremento de capacidad del modelo mediante YOLO11s no produjo mejoras en las métricas evaluadas. Por el contrario, se observó una disminución del desempeño, pasando de 45.71% a 41.51% en mAP@0.5. Esto indica que, bajo las condiciones del presente estudio, una arquitectura más compleja no garantiza mejores resultados cuando existe una cantidad limitada de datos de entrenamiento.

Por otro lado, la comparación entre V3 y V5 permitió evaluar el efecto de la eliminación de anotaciones microscópicas consideradas como posibles errores de etiquetado. Los resultados fueron similares, con una variación mínima en mAP@0.5 (45.71% frente a 45.05%), indicando que la limpieza de anotaciones no produjo una mejora significativa utilizando el tamaño actual del conjunto de validación.

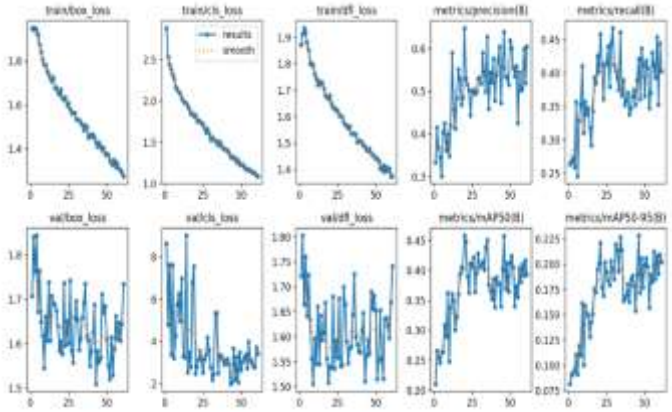
En consecuencia, los experimentos realizados sugieren que la principal limitación del sistema corresponde a la cantidad y diversidad del conjunto de datos, más que a la arquitectura seleccionada o al proceso de limpieza de etiquetas.

B. Análisis de las curvas de entrenamiento

La Figura 7 presenta la evolución de las pérdidas y métricas obtenidas durante el entrenamiento del modelo YOLO11n seleccionado.

Figura 7

Curvas de entrenamiento del modelo YOLO11n



Las curvas muestran una reducción progresiva de las funciones de pérdida (*box loss*, *classification loss* y *DFL loss*) durante el entrenamiento, indicando que el modelo logró aprender características asociadas a la detección de Pseudococcidae.

Asimismo, las métricas de precisión, Recall y mAP presentan una tendencia creciente durante las primeras épocas, alcanzando los mejores valores aproximadamente alrededor de la época 46. Posteriormente, las métricas muestran cierta estabilización, lo que evidencia una posible saturación del aprendizaje y una ligera tendencia al sobreajuste.

Este comportamiento confirma que el modelo logró adaptarse al conjunto de entrenamiento; sin embargo, la limitada variabilidad de las imágenes disponibles restringe su capacidad de generalización hacia nuevos escenarios.

C. Análisis de las curvas de entrenamiento

Los experimentos realizados permiten observar que las mejoras obtenidas no dependen únicamente de la selección del modelo, sino principalmente de la disponibilidad de datos representativos. Aunque se evaluó una arquitectura con mayor número de parámetros (YOLO11s), esta presentó menor desempeño debido posiblemente a una mayor susceptibilidad al sobreajuste.

Además, la depuración de cuadros delimitadores pequeños no generó cambios significativos en los resultados, lo cual indica que el ruido de anotación no constituye la principal limitación del sistema. Por ello, una estrategia futura de mejora debe enfocarse en ampliar la diversidad del dataset mediante imágenes obtenidas bajo diferentes condiciones de iluminación, orientación y escenarios reales de cultivo.

V. DISCUSIÓN

Los resultados obtenidos evidencian que los modelos basados en visión por computadora y aprendizaje profundo presentan viabilidad para la detección automática de Pseudococcidae en cultivos de vid. La configuración con YOLO11n alcanzó el mejor desempeño entre los experimentos realizados, demostrando que una arquitectura ligera puede ser suficiente para abordar tareas de detección de plagas cuando se cuenta con recursos computacionales limitados.

La reducción del problema inicial de tres clases a una única clase correspondiente a Pseudococcidae permitió mejorar la capacidad de aprendizaje del modelo, debido a que se eliminó el efecto generado por el fuerte desbalance entre categorías. Este resultado coincide con investigaciones previas en detección de plagas agrícolas, donde la calidad y distribución de los datos representan factores determinantes para obtener modelos robustos.

Asimismo, la comparación entre YOLO11n y YOLO11s mostró que el aumento de la complejidad del modelo no garantizó una mejora en el desempeño. Aunque YOLO11s posee una mayor cantidad de parámetros y capacidad de representación, obtuvo menores valores de precisión y mAP. Este comportamiento puede atribuirse a la cantidad limitada de imágenes disponibles para entrenamiento, ya que modelos con mayor capacidad requieren conjuntos de datos más amplios para evitar problemas de sobreajuste.

Por otro lado, la depuración de anotaciones con cuadros delimitadores extremadamente pequeños no generó una mejora significativa en las métricas obtenidas. Esto indica que, para el conjunto evaluado, la principal limitación no se encontraba en la presencia de ruido de etiquetado, sino en la variabilidad insuficiente de las imágenes utilizadas durante el entrenamiento.

Un aspecto relevante identificado durante la evaluación fue la diferencia entre las imágenes del dataset público y las fotografías reales obtenidas en cultivos de vid de Gran Chimú. Mientras que el conjunto de entrenamiento presenta imágenes con características relativamente controladas, las imágenes de campo incluyen variaciones de iluminación, fondos complejos, diferentes distancias de captura y cambios en la apariencia de la plaga. Esta diferencia evidencia la existencia de un cambio de dominio (*domain shift*), el cual afecta la capacidad de generalización del modelo.

Los resultados obtenidos presentan diferencias respecto a algunos estudios previos que reportan valores superiores de precisión en detección de plagas agrícolas. Sin embargo, dichos trabajos suelen utilizar conjuntos de datos más grandes, condiciones de captura controladas o imágenes tomadas en escenarios específicos. En contraste, el presente estudio aborda una problemática más cercana a condiciones reales de campo, donde la variabilidad visual representa un desafío adicional.

En este sentido, aunque el modelo desarrollado no alcanza valores de desempeño cercanos a aplicaciones industriales, demuestra la factibilidad de utilizar YOLO11 como herramienta de apoyo para el monitoreo fitosanitario de cultivos de vid. Las principales oportunidades de mejora se encuentran relacionadas con la ampliación del dataset mediante imágenes locales, la incorporación de diferentes etapas fenológicas del cultivo y el entrenamiento con muestras obtenidas bajo diversas condiciones ambientales.

VI. CONCLUSIONES

Se desarrolló e implementó un sistema de visión por computadora basado en la arquitectura YOLO11 capaz de detectar y localizar automáticamente individuos de la familia Pseudococcidae en imágenes digitales de cultivos de vid, cumpliendo con el objetivo general planteado. El sistema entrega como salida la imagen analizada con cuadros delimitadores, la clase asociada y el nivel de confianza de cada predicción, lo que constituye una herramienta de apoyo al monitoreo fitosanitario y no un reemplazo de la inspección realizada por el personal agrícola.

La configuración V3, basada en YOLO11n, obtuvo el mejor desempeño global entre las variantes evaluadas, con una precisión de 62.84 %, una sensibilidad de 42.13 %, un F1-score de 50.44 % y un mAP@0.5 de 45.71 %, superando al modelo público de referencia entrenado sobre el mismo conjunto de datos. Estos valores demuestran que el enfoque propuesto aporta una mejora verificable sobre la línea base disponible, aun cuando el desempeño alcanzado todavía resulta insuficiente para un despliegue operativo autónomo.

El tiempo de inferencia de 13.8 ms por imagen confirma la viabilidad computacional del sistema para su ejecución en tiempo casi real sobre hardware de gama media, incluso con recursos limitados de memoria de video (4 GB VRAM). Esta característica respalda la factibilidad técnica de una futura integración del modelo en dispositivos móviles o de borde destinados a las labores de campo.

La reducción del problema original de tres clases (Grape, Leaf y Pseudococcidae) a una única clase de interés permitió eliminar el efecto del desbalance entre categorías y mejorar la capacidad de aprendizaje del modelo, lo que confirma que la distribución de las clases constituye un factor determinante en el entrenamiento de detectores de plagas agrícolas.

El estudio de ablación realizado sobre cuatro hipótesis de mejora evidenció que el incremento de la capacidad del modelo no se traduce en un mejor desempeño: la variante con YOLO11s redujo el mAP@0.5 de 45.71 % a 41.51 %, comportamiento atribuible a una mayor susceptibilidad al sobreajuste ante un conjunto de entrenamiento reducido. Del mismo modo, la depuración de anotaciones microscópicas produjo una variación mínima (45.05 % frente a 45.71 %), lo que descarta al ruido de etiquetado como limitación principal. En consecuencia, se concluye que el factor restrictivo del sistema reside en la cantidad y diversidad del conjunto de datos, y no en la arquitectura seleccionada ni en la calidad de las anotaciones.

El análisis de las curvas de entrenamiento mostró una disminución sostenida de las funciones de pérdida (box loss, classification loss y DFL loss) y un desempeño óptimo alrededor de la época 46, seguido de una estabilización de las métricas. Este patrón indica que el modelo agotó la información aprovechable del conjunto disponible, de manera que ampliar el número de épocas no constituye una vía de mejora frente a la ampliación del corpus de imágenes.

La evaluación cualitativa sobre fotografías propias capturadas en cultivos de vid de la provincia de Gran Chimú evidenció una limitación de generalización asociada a un cambio de dominio (*domain shift*), originado por las diferencias en iluminación, complejidad del fondo, distancia de captura y apariencia de la plaga entre el dataset público y las condiciones reales de campo. Por lo tanto, la incorporación de imágenes representativas del contexto local, anotadas y capturadas en distintas etapas fenológicas del cultivo, constituye un requisito indispensable —y no una mejora opcional— para el despliegue del sistema en la provincia.

En términos generales, la investigación aporta evidencia sobre la aplicabilidad de los modelos de detección de una sola etapa al monitoreo de Pseudococcidae en vid bajo condiciones cercanas a las reales, y establece una línea base metodológica reproducible para trabajos posteriores en la región La Libertad. Las principales direcciones de trabajo futuro comprenden la construcción de un dataset local anotado, la aplicación de técnicas de adaptación de dominio o *fine-tuning* con imágenes de campo, la exploración de estrategias de detección de objetos pequeños y la validación del sistema en condiciones operativas junto a personal técnico agrícola.

REFERENCIAS

Basilio Vela, O. A. (2016). *Estudio de un sistema de visión para control de pesos y tamaño de racimos de uva de mesa* [Tesis de maestría, Pontificia Universidad Católica del Perú]. Repositorio Digital de Tesis PUCP. http://hdl.handle.net/20.500.12404/6985

Chen, J.-W., Lin, W.-J., Cheng, H.-J., Hung, C.-L., Lin, C.-Y., & Chen, S.-P. (2021). A smartphone-based application for scale pest detection using multiple-object detection methods. *Electronics, 10*(4), 372. https://doi.org/10.3390/electronics10040372

Gobierno Regional de La Libertad. (2024, 31 de julio). *Gran Chimú: se realizó con éxito la XXII Feria Regional de la Uva*. https://www.regionlalibertad.gob.pe/noticias/regionales/14834-gran-chimu-se-realizo-con-exito-la-xxii-feria-regional-de-la-uva

Jocher, G., & Qiu, J. (2024). *Ultralytics YOLO11* (Versión 11.0.0) [Software]. Ultralytics. https://github.com/ultralytics/ultralytics

Narciso Horna, W. A., & Manzano Ramos, E. A. (2021). Sistema de visión artificial basado en redes neuronales convolucionales para la selección de arándanos según estándares de exportación. *Campus, 26*(32), 155–166. https://doi.org/10.24265/campus.2021.v26n32.01

Portal Frutícola. (2023, 9 de mayo). *Perú: el impulso de la temporada de uva de mesa se lo llevan las blancas sin semilla*. https://www.portalfruticola.com/noticias/2023/05/09/peru-el-impulso-de-la-temporada-de-uva-de-mesa-se-lo-llevan-las-blancas-sin-semilla/

Roboflow. (s. f.). *Mealybug* (Versión 8) [Conjunto de datos]. Roboflow Universe. https://universe.roboflow.com/grape-n5yol/mealybug-b8wfq/dataset/8

Servicio Nacional de Sanidad Agraria. (2026). *MIDAGRI: Perú supera las 706 mil toneladas de uva exportada empleando tratamiento cuarentenario en frío*. Plataforma del Estado Peruano. https://www.gob.pe/institucion/senasa/noticias/1382581-midagri-peru-supera-las-706-mil-toneladas-de-uva-exportada-empleando-tratamiento-cuarentenario-en-frio

Wu, X., Zhan, C., Lai, Y.-K., Cheng, M.-M., & Yang, J. (2019). IP102: A large-scale benchmark dataset for insect pest recognition. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 8787–8796). IEEE. https://openaccess.thecvf.com/content_CVPR_2019/html/Wu_IP102_A_Large-Scale_Benchmark_Dataset_for_Insect_Pest_Recognition_CVPR_2019_paper.html

Zheng, Y.-Y., Kong, J.-L., Jin, X.-B., Wang, X.-Y., Su, T.-L., & Zuo, M. (2019). CropDeep: The crop vision dataset for deep-learning-based classification and detection in precision agriculture. *Sensors, 19*(5), 1058. https://doi.org/10.3390/s19051058

ANEXOS